Basi di Dati Ottimizzazione del DBMS

Corso B

Base dati di esempio

PA7IFNTI

<u> </u>				
COD	Cognome	Nome	Residenza	AnnoNascita
A102	Necchi	Luca	ТО	1950
B372	Rossigni	Piero	NO	1940
B543	Missoni	Nadia	ТО	1960
B444	Missoni	Luigi	VC	2000
S555	Rossetti	Gino	AT	2010

REPARTI

<u>COD</u>	Nome-Rep	Primario
Α	Chirurgia	203
В	Pediatria	574
С	Medicina	530
L	Lab-Analisi	530
R	Radiologia	405

RICOVERI

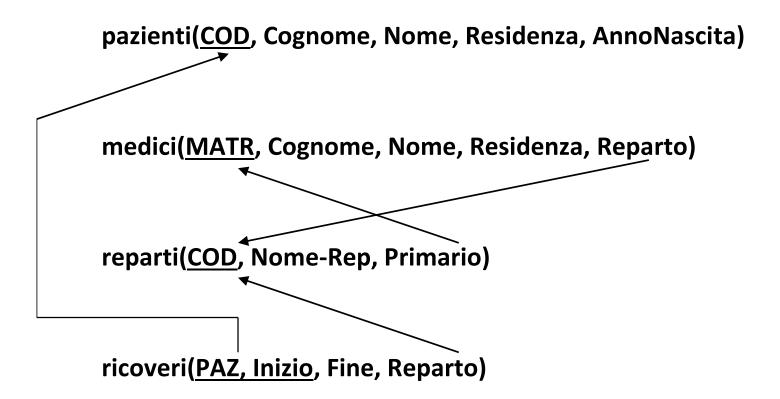
TRIOCYLIN				
PAZ	Inizio	Fine	Reparto	
A102	2/05/2004	9/05/2004	А	
A102	2/12/2004	2/01/2005	Α	
S555	5/10/2014	3/12/2014	В	
B444	1/12/2004	2/01/2005	В	
S555	6/09/2015	1/11/2015	A	

MEDICI

MATR	Cognome	Nome	Residenza	Reparto
203	Neri	Piero	AL	Α
574	Bisi	Mario	MI	В
461	Bargio	Sergio	ТО	В
530	Belli	Nicola	то	С
405	Mizzi	Nicola	AT	R
501	Monti	Mario	VC	A

Base dati di esempio

Schema relazionale con vincoli di integrità referenziali:



Base di Dati "Impiegati"

IMPIEGATI

<u>MATR</u>	Cognome	Nome	Età	Stipendio
203	Neri	Piero	50	40
574	Bisi	Mario	60	60
461	Bargio	Sergio	30	61
530	Belli	Nicola	40	38
405	Mizzi	Nicola	55	60
501	Monti	Mario	25	35

IMPIEGATI(MATR, Cognome, Nome, Età, Stipendio)

ORGANIGRAMMA(Capo,Impiegato)

ORGANIGRAMMA

CINCAMIGINAMINA				
Саро	Impiegato			
203	405			
203	501			
574	203			
574	530			
405	461			

Ottimizzazione delle interrogazioni

 Ottimizzare: fare in modo che l'implementazione dell'interrogazione risulti più veloce possibile

 Ci occuperemo di ottimizzazione in tempo (più che sull'ottimizzazione in memoria/spazio)

- L'applicazione gira in memoria centrale e dialoga attraverso il DBMS
- Il DBMS dialoga con le periferiche di storage attraverso il gestore del buffer (gestisce pagine di memoria)
- Le pagine sono mappate sul dispositivo di storage
- Un'attività (processo) in memoria centrale lavora con tempi dell'ordine dei nanosecondi (10⁻⁹ secondi)

- Quando l'applicazione ha bisogno di una tupla chiede al DBMS di fornirgliela
- Il DBMS deve trasferire una pagina dalla periferica di storage alla memoria centrale (buffer)
- Quando la pagina con la tupla richiesta è nel buffer,
 l'applicazione può elaborarla

 Il DBMS deve trasferire una pagina dalla periferica di storage alla memoria centrale (buffer)

L'ordine di grandezza di questa operazione è il millisecondo (10⁻³ secondi)

Confrontato con i tempi di lavoro del processo in memoria principale, è un milione di volte più lenta!

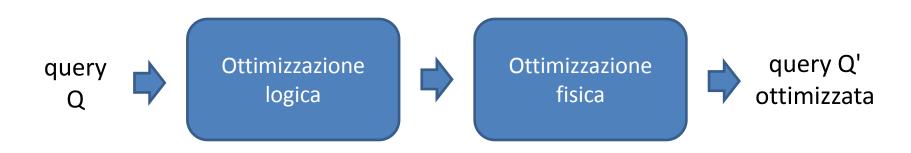
La complessità delle attività "algoritmiche" del DBMS in memoria principale è minima (solo loop, confronti, copia e trasferimento di dati)

Se i DBMS vogliono minimizzare i tempi di risposta devono minimizzare il trasferimento di pagine

L'obiettivo dell'ottimizzatore del DBMS è di minimizzare il trasferimento di pagine da e verso la memoria centrale

Ottimizzazione in due fasi

Tutti i DBMS realizzano l'ottimizzazione dell'interrogazione Q (espressa in algebra relazionale) in due fasi:



Q' è il piano operativo per l'esecuzione dell'interrogazione

Ottimizzazione logica

L'ottimizzazione logica è indipendente dalle strutture di memorizzazione

L'ottimizzazione logica prende in input l'albero di parsificazione (albero sintattico) scritto dall'utente e lo trasforma sfruttando le proprietà dell'algebra relazionale

L'albero in uscita è perfettamente equivalente all'interrogazione originale

Ottimizzazione fisica

- L'albero prodotto in output dall'ottimizzatore logico, diventa l'input dell'ottimizzatore fisico
- L'ottimizzatore fisico prenderà in considerazione le strutture interne di memorizzazione
- L'ottimizzatore fisico entra nei nodi (operatori) dell'albero di parsificazione, li esamina e in base alle strutture fisiche sceglie l'algoritmo ottimale per eseguirli
- Alla fine l'albero di parsificazione avrà, come nodi, gli algoritmi più adatti per l'esecuzione ottimale dei nodi

Esempio di albero

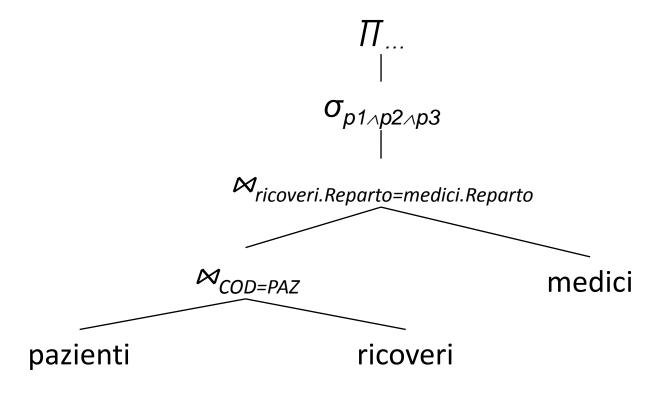
$$\Pi_{...}(\sigma_{pazienti.Residenza='TO' \land Inizio='2010' \land MATR='405'}((pazienti \bowtie_{COD=PAZ} ricoveri) \bowtie_{ricoveri.Reparto=medici.Reparto} medici))$$

Chiamo

- p1= pazienti.Residenza='TO'
- p2=Inizio='2010'
- p3=MATR='405'

Esempio di albero

 $\Pi_{...}(\sigma_{p1 \land p2 \land p3}((pazienti \bowtie_{COD=PAZ} ricoveri))$ $\bowtie_{ricoveri.Reparto=medici.Reparto} medici))$



Ottimizzazione logica

L'ottimizzatore è guidato da un semplice principio euristico:

- L'interrogazione da un punto di vista logico coinvolge una massa di tuple notevole (pensiamo al join)
- L'ottimizzatore cerca di ridurre il più drasticamente possibile il numero di tuple coinvolte dall'interrogazione

Obiettivo: ridurre la massa di tuple concettualmente coinvolte dall'interrogazione

Ottimizzazione logica

- Si è dimostrato nei fatti che quando l'ottimizzatore fisico deve lavorare sui dati, produce i risultati migliori se riceve in input un albero di parsificazione che ha ridotto il numero di tuple concettualmente coinvolte dall'interrogazione
- L'influenza positiva dell'ottimizzazione logica si riscontra nelle grandi applicazioni gestionali dei sistemi informativi (la maggioranza delle applicazioni su basi di dati)
- In generale, però, l'euristica non è sempre valida

Euristica dell'ottimizzatore

Quasi tutte le operazioni principali dei sistemi informativi che usiamo quotidianamente sono mirate a lavorare su pochissimi dati:

- lavoro sul mio piano di studi, non su tutti
- lavoro sui miei pazienti, non su tutti
- lavoro sulle operazioni del mio conto in banca, non su tutte

Entra quindi in gioco la selezione

Euristica dell'ottimizzazione

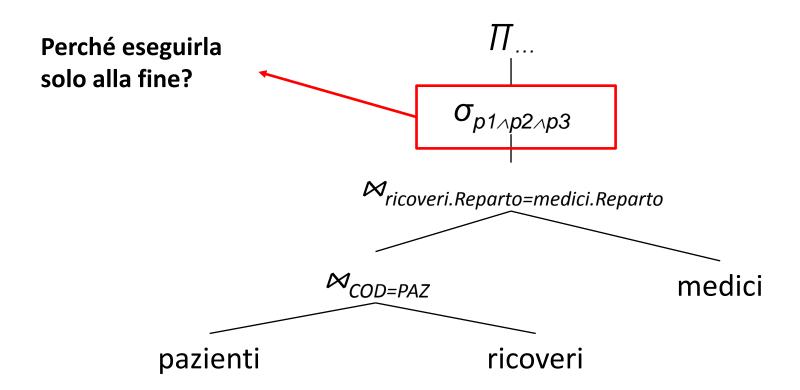
Dato che nelle applicazioni dei sistemi informativi l'attenzione è su un numero limitato di tuple, posso fare in modo che la selezione sia uno dei primi operatori da eseguire, riducendo subito il numero di tuple coinvolte?

Posso farlo grazie alle **proprietà distributive della selezione**!

L'ottimizzatore cerca, con un algoritmo, di applicare questa semplice euristica

Esempio di albero

 $\Pi_{...}(\sigma_{p1 \land p2 \land p3}((pazienti \bowtie_{COD=PAZ} ricoveri))$ $\bowtie_{ricoveri.Reparto=medici.Reparto} medici))$



Algoritmo di ottimizzazione logica

I predicati p della selezione sono in forma congiuntiva (non è una limitazione: qualsiasi predicato si può ricondurre alla forma congiuntiva con De Morgan)

- Decomposizione degli AND
 - $\qquad \sigma_{p1 \wedge p2}(r) \rightarrow \sigma_{p1}(\sigma_{p2}(r))$
- Trasferire le selezioni verso le foglie finché è possibile con le proprietà distributive della selezione
- Trasferire le proiezioni verso le foglie finché è possibile con le proprietà distributive della proiezione

Algoritmo di ottimizzazione logica

- 4. Ricondurre ad un'unica selezione le selezioni multiple
 - $\qquad \sigma_{p1}(\sigma_{p2}(r)) \rightarrow \sigma_{p1 \wedge p2}(r)$
- 5. Riconoscere le sequenze di join
 - $\sigma_{\theta}(r \times s) \rightarrow r \bowtie_{\theta} s$
- 6. Ricondurre ad un'unica proiezione le proiezioni multiple
 - $\qquad \prod_{X} \prod_{X,Y} (r) \rightarrow \prod_{X} (r)$
- 7. Esame delle varianti dell'albero di parsificazione dovute alle proprietà associative (scegliere la variante di costo minimo)

I predicati p della selezione sono in forma congiuntiva (non è una limitazione: qualsiasi predicato si può ricondurre alla forma congiuntiva con De Morgan)

1. Decomposizione degli AND

$$- \qquad \sigma_{p1 \wedge p2}(r) \rightarrow \sigma_{p1}(\sigma_{p2}(r))$$

- Trasferire le selezioni verso le foglie finché è possibile con le proprietà distributive della selezione
- Trasferire le proiezioni verso le foglie finché è possibile con le proprietà distributive della proiezione

Vediamo la proprietà distributiva della selezione rispetto al join:

$$\sigma_p(r(A) \bowtie_{\Theta} s(B)) \rightarrow \sigma_p(r(A)) \bowtie_{\Theta} s(B)$$

Valida **solo se** gli attributi coinvolti da *p* sono contenuti nello schema *A* (o nello schema *B*)

Ma, ad una selezione con un predicato che pesca da più relazioni difficilmente può essere applicata la proprietà distributiva

Infatti, nell'esempio ho

$$\sigma_{p1 \wedge p2 \wedge p3}$$

con

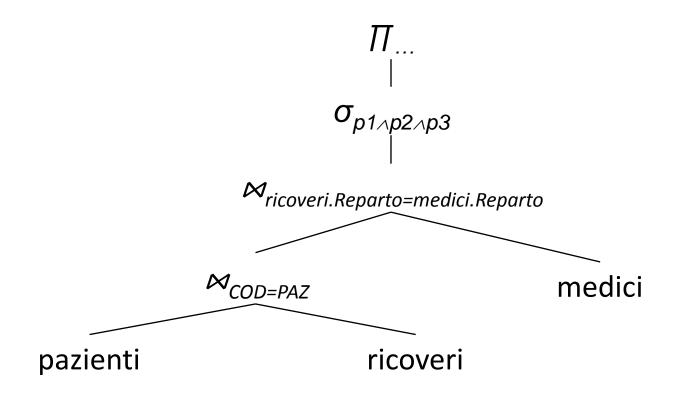
```
p1= pazienti.Residenza='TO' (che pesca da pazienti)
p2=Inizio='2010' (che pesca da ricoveri)
p3=MATR='405' (che pesca da medici)
```

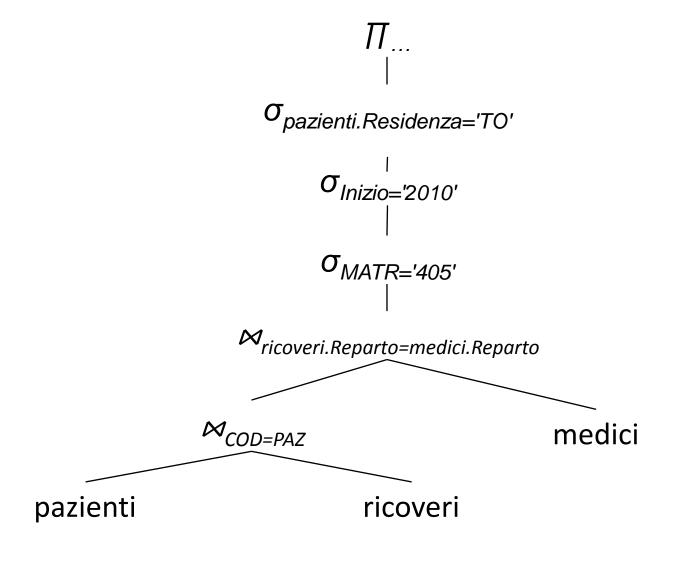
Questo predicato non consente di muovere la selezione da dov'è sfruttando la proprietà distributiva della selezione rispetto al join

Ma se la spezzo in

$$\sigma_{p1}\sigma_{p2}\sigma_{p3}$$

i singoli predicati sono più semplici e aumento la probabilità che essi soddisfino la condizione necessaria all'applicazione della proprietà distributiva



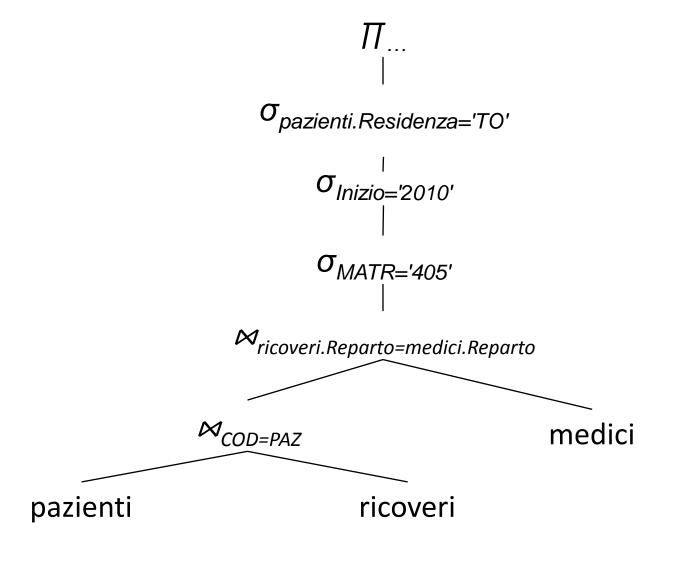


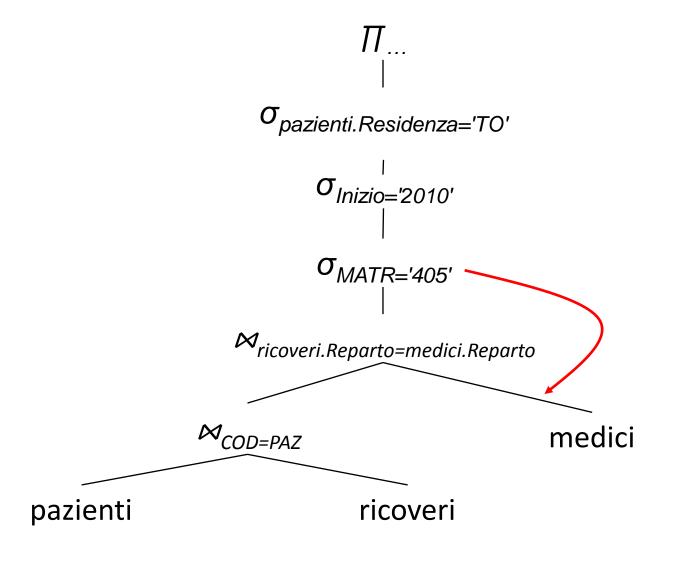
I predicati p della selezione sono in forma congiuntiva (non è una limitazione: qualsiasi predicato si può ricondurre alla forma congiuntiva con De Morgan)

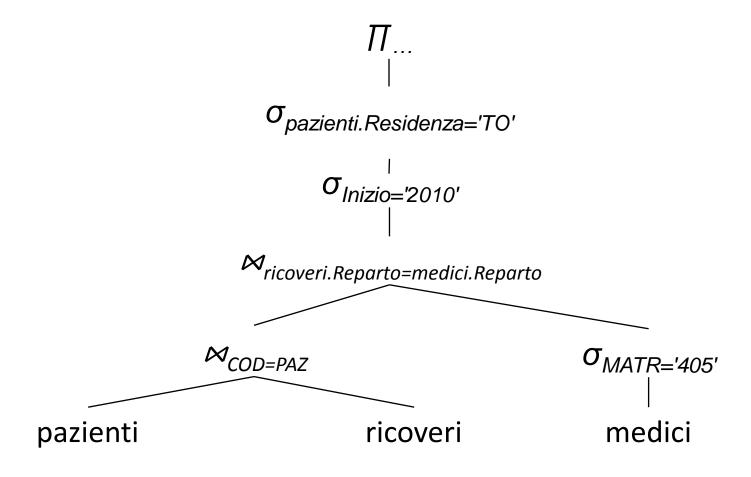
- Decomposizione degli AND
 - $\qquad \sigma_{p1 \wedge p2}(r) \rightarrow \sigma_{p1}(\sigma_{p2}(r))$
- 2. Trasferire le selezioni verso le foglie finché è possibile con le proprietà distributive della selezione
- Trasferire le proiezioni verso le foglie finché è possibile con le proprietà distributive della proiezione

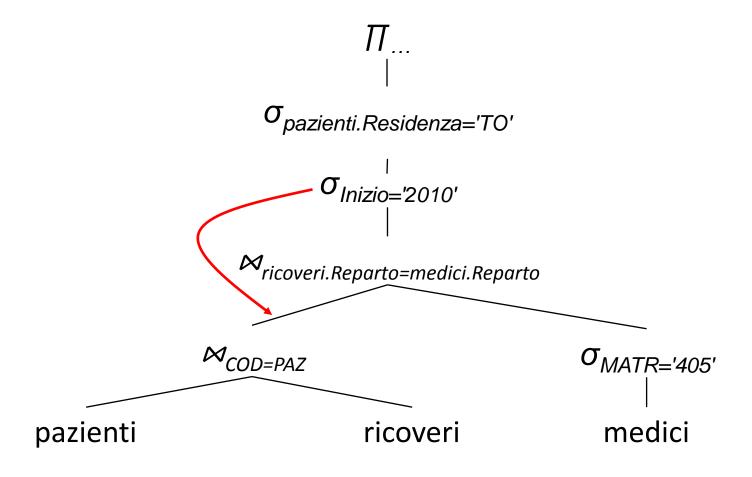
Spiegazione del punto 2

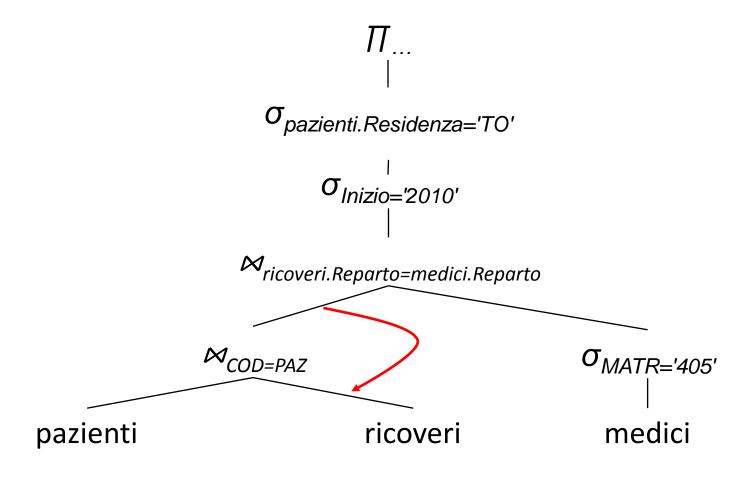
A questo punto si può applicare il punto 2, trasferire le selezioni verso le foglie

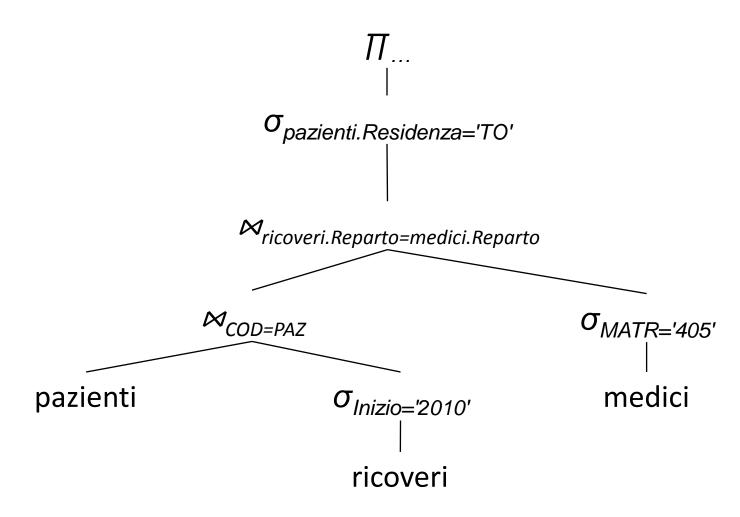


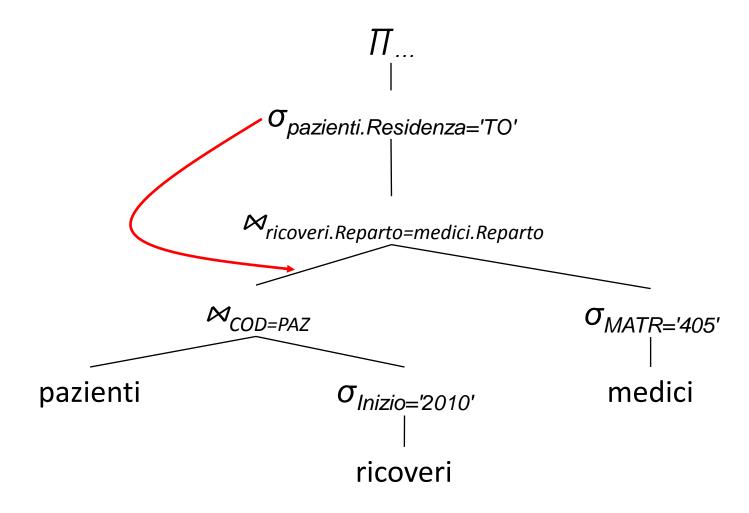




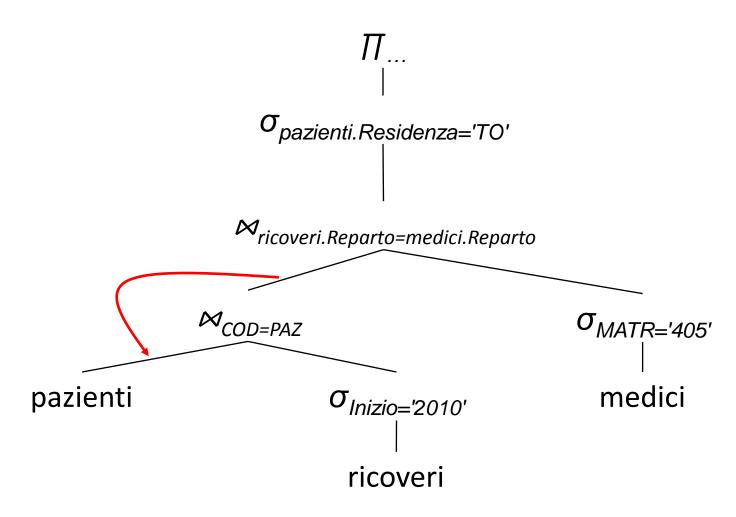




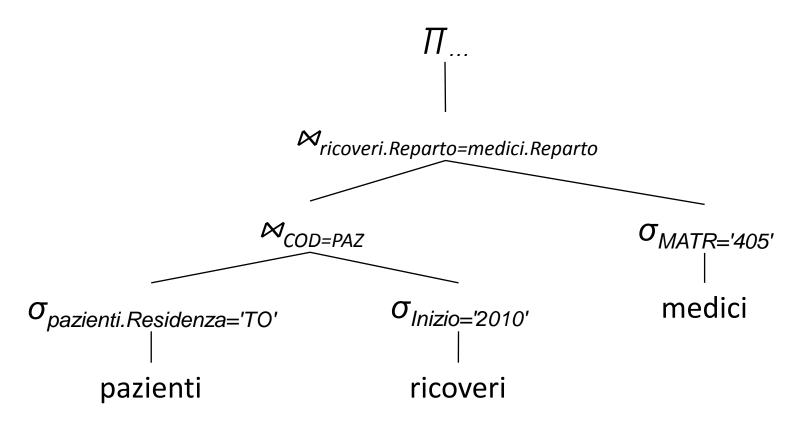




Esecuzione del passo 2



Esecuzione del passo 2



4. Ricondurre ad un'unica selezione le selezioni multiple

$$- \quad \sigma_{p1}(\sigma_{p2}(r)) \rightarrow \sigma_{p1 \wedge p2}(r)$$

5. Riconoscere le sequenze di join

$$- \sigma_{\theta}(r \times s) \rightarrow r \bowtie_{\theta} s$$

6. Ricondurre ad un'unica proiezione le proiezioni multiple

$$- \prod_{X} \prod_{X,Y} (r) \rightarrow \prod_{X} (r)$$

7. Esame delle varianti dell'albero di parsificazione dovute alle proprietà associative (scegliere la variante di costo minimo)

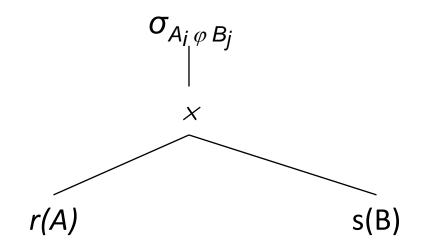
 A forza di trasferire le selezioni, le selezioni si fermano sui sottoalberi di competenza

 Potremmo quindi trovare delle selezioni in cascata (selezioni multiple)

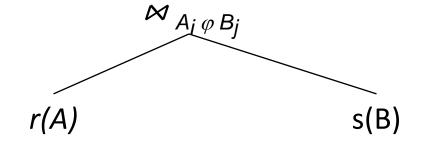
 L'ottimizzatore ricompone insieme le selezioni multiple, applicando una sola selezione con una congiunzione di predicati

- 4. Ricondurre ad un'unica selezione le selezioni multiple
 - $\qquad \sigma_{p1}(\sigma_{p2}(r)) \rightarrow \sigma_{p1 \wedge p2}(r)$
- 5. Riconoscere le sequenze di join
 - $\sigma_{\theta}(r \times s) \rightarrow r \bowtie_{\theta} s$
- 6. Ricondurre ad un'unica proiezione le proiezioni multiple
 - $\prod_{X} \prod_{X,Y} (r) \rightarrow \prod_{X} (r)$
- 7. Esame delle varianti dell'albero di parsificazione dovute alle proprietà associative (scegliere la variante di costo minimo)

Capita molto spesso, anche in SQL, di trovarsi con delle selezioni con sottoalbero un prodotto cartesiano



Il passo 5 trasforma quindi il sottoalbero in un thetajoin (tutti i DBMS hanno infatti algoritmi ottimizzati per eseguire i join)



- 4. Ricondurre ad un'unica selezione le selezioni multiple
 - $\qquad \sigma_{p1}(\sigma_{p2}(r)) \rightarrow \sigma_{p1 \wedge p2}(r)$
- 5. Riconoscere le sequenze di join
 - $\sigma_{\theta}(r \times s) \rightarrow r \bowtie_{\theta} s$
- 6. Ricondurre ad un'unica proiezione le proiezioni multiple
 - $\qquad \prod_{X} \prod_{X,Y} (r) \rightarrow \prod_{X} (r)$
- 7. Esame delle varianti dell'albero di parsificazione dovute alle proprietà associative (scegliere la variante di costo minimo)

La spiegazione è intuitiva!

Aspetti quantitativi delle interrogazioni

I DBMS mantengono nel dizionario dati una serie di informazioni di tipo statistico su ogni tavola *r*, in particolare:

- cardinalità della relazione CARD(r) = |r|
- ampiezza della tupla in byte SIZE(t)
- $VAL(A_i, r)$ il numero di valori distinti che appare nella colonna A_i all'interno della tavola r, ovvero

$$VAL(A_{i'}r) = \prod_{A_i} (r)$$

- Ad esempio VAL(Reparto, ricoveri) = 2
- Se A_i è chiave, $VAL(A_i, r) = CARD(r)$

Aspetti quantitativi delle interrogazioni

I DBMS mantengono nel dizionario dati una serie di informazioni di tipo statistico su ogni tavola *r*, in particolare:

- $MIN(A_i, r)$, il valore minimo di A_i contenuto in r
- $MAX(A_i,r)$, il valore massimo di A_i contenuto in r

- NPAGE(r) = CARD(r)/fattore_di_bloccaggio
 - fattore_di_bloccaggio è il numero massimo di tuple che una pagina può contenere

Analisi dei costi delle interrogazioni

L'analisi quantitativa dell'interrogazione permette di predire *ex-ante* il risultato della cardinalità della relazione risultato senza eseguirla

Stima del costo della selezione

Data la selezione $\sigma_p(r)$, conoscendo l'intervallo di variabilità della selezione $\sigma_p(r)$

$$0 \le |\sigma_p(r)| \le |r|$$

si può modellare la cardinalità della selezione $\sigma_{\rho}(r)$ con un **fattore di selettività f_{\rho}** per la cardinalità di r

$$|\sigma_p(r)| = f_p \cdot |r|$$

Il fattore di selettività è legato al solo predicato *p* di selezione e varia tra 0 e 1

Fattore di selettività

Il fattore di selettività f_{ρ} può essere interpretato come la probabilità che una tupla in r soddisfi il predicato di selezione p, ovvero la stima della percentuale di tuple che soddisfano il predicato di selezione

Come possiamo stimare f_p ?

Fattore di selettività

I DBMS hanno a disposizione un formulario anche molto avanzato per il calcolo del fattore di selettività $f_{
ho}$

Noi forniremo una versione più grossolana, ma sufficiente ai nostri scopi

Considereremo quindi una distribuzione uniforme dei valori all'interno delle varie colonne

Tabella del fattore di selettività

• Predicati atomici

Predicato p	f _p
$A_i = V$	1/VAL(A _i , r)
$A_i \leq V$	$(v - MIN(A_i, r))/(MAX(A_i, r) - MIN(A_i, r))$
$A_i \ge V$	$(MAX(A_i, r) - v)/(MAX(A_i, r) - MIN(A_i, r))$
$V_1 \le A_i \le V_2$	$(v_2 - v_1)/(MAX(A_i, r) - MIN(A_i, r))$

Tabella del fattore di selettività

Predicati composti

Predicato p	f _p
$p_1 \land p_2 \land \land p_n$	$f_{p_1} \cdot f_{p_2} \cdot \dots \cdot f_{p_n}$
¬р	1 – f _p
$p_1 \lor p_2 \lor \lor p_n$	$1 - ((1 - f_{p_1}) \cdot (1 - f_{p_2}) \cdot \cdot (1 - f_{p_n}))$

L'OR si dimostra con De Morgan:

$$\neg\neg(p_1\lor p_2\lor...\lor p_n)=\neg(\neg p_1\land\neg p_2\land...\land\neg p_n)$$

Per i nostri scopi, ci limiteremo a studiare l'equi-join $|r(A)\bowtie_{A_i=B_i}s(B)|$

• Se esiste un vincolo di integrità referenziale $r(...A_{i}...) \rightarrow s(...B_{j}...)$, la cardinalità dell'equi-join è $|r(A) \bowtie_{A_i = B_j} s(B)| = |r(A)| = CARD(r)$

In generale, per stimare

$$|r(A)\bowtie_{A_i=B_i}s(B)|$$

Immaginiamo di prendere **una tupla** di r che in corrispondenza dell'attributo A_i trova un ben preciso valore v, e in s ci siano diverse tuple con valore v

L'equi-join produrrà in uscita la giustapposizione della tupla di r per cui $A_i = v$ con le tuple di s per cui $B_j = v$

La cardinalità della selezione con predicato $p: B_j = v$ è $(1/VAL(B_i, s)) \cdot CARD(s)$, numero delle tuple giustapposte a t

Possiamo ora stimare la cardinalità completa del join estendendolo a tutte le tuple *t* della relazione *r*

La cardinalità del join diventa quindi:

$$|r(A)\bowtie_{A_i=B_i} s(B)| = (1/VAL(B_j, s)) \cdot CARD(s) \cdot CARD(r)$$

Non ho ancora finito!

Posso partire da s

Immaginiamo di prendere **una tupla** di s che in corrispondenza dell'attributo B_j trova un ben preciso valore v, e in r ci siano diverse tuple con valore v

L'equi-join produrrà in uscita la giustapposizione della tupla di s per cui $B_i = v$ con le tuple di r per cui $A_i = v$

La cardinalità della selezione con predicato $p: A_i = v$ è $(1/VAL(A_i, r)) \cdot CARD(r)$, numero delle tuple giustapposte a t

Possiamo ora stimare la cardinalità completa del join estendendolo a tutte le tuple t della relazione s

La cardinalità del join diventa quindi:

$$|r(A)\bowtie_{A_i=B_i} s(B)| = (1/VAL(A_i, r)) \cdot CARD(r) \cdot CARD(s)$$

Cambia solo il fattore di selettività:

$$1/VAL(A_{i'}, r)$$
 oppure $1/VAL(B_{i'}, s)$?

Entrambe le formule sono delle sovrastime, possiamo quindi considerare il minimo delle due

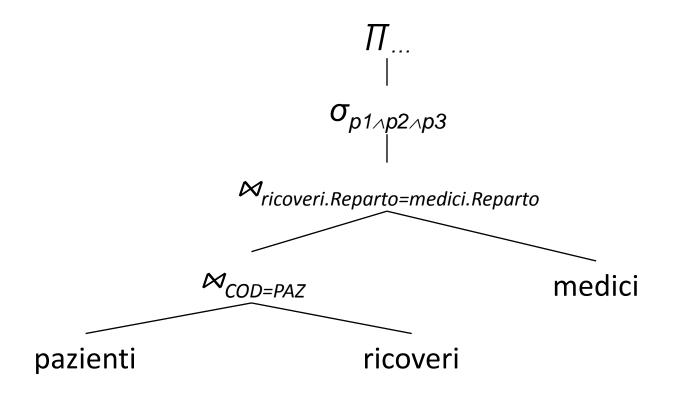
La cardinalità del join diventa infine:

$$|r(A)\bowtie_{A_i=B_j} s(B)| = min\{1/VAL(A_i, r), 1/VAL(B_i, s)\}\cdot CARD(r) \cdot CARD(s)$$

$$\Pi_{...}(\sigma_{pazienti.Residenza='TO' \land Inizio='2010' \land MATR='405'}((pazienti \bowtie_{COD=PAZ} ricoveri) \bowtie_{ricoveri.Reparto=medici.Reparto} medici))$$

Con

- p1= pazienti.Residenza='TO'
- p2=Inizio='2010'
- p3=MATR='405'



Dizionario dati:

- CARD(pazienti) = 10⁵
- CARD(ricoveri)= 10⁵
- CARD(medici)= 100
- VAL(Inizio, ricoveri) = 10 (dieci anni)
- VAL(Reparto, ricoveri) = 10
- VAL(Residenza, pazienti) = 100
- VAL(PAZ,ricoveri) = 10⁵
- VAL(Reparto, medici) = 10

Posso già calcolare i fattori di selettività dei predicati

- p1= pazienti.Residenza='TO'
- p2=Inizio='2010'
- p3=MATR='405'

cioè

- $f_{p1} = 1/(VAL(Residenza, pazienti) = 1/100$
- $f_{p2} = 1/(VAL(Inizio,ricoveri) = 1/10$
- $f_{n3} = 1/(VAL(MATR, medici)) = 1/(CARD(medici)) = 1/100$

Semplificazione: da un punto di vista concettuale il join $pazienti \bowtie_{COD=PAZ} ricoveri$

elabora un numero di tuple pari al prodotto di delle cardinalità delle due relazioni, quindi:

 $10^5 \cdot 10^5 = 10^{10}$ (dieci miliardi)

per produrre quante tuple?

Dobbiamo valutare la cardinalità del join

Valutiamo la cardinalità del join pazienti ⋈_{COD=PAZ} ricoveri

E' possibile usare la formula precisa in quanto *COD* è chiave di pazienti, ed esiste un vincolo di integrità referenziale tra ricoveri e pazienti, quindi

 $|pazienti\bowtie_{COD=PAZ} ricoveri| = CARD(ricoveri) = 10^5$

Ora devo effettuare il join del risultato del join precedente (r1) con medici

r1 ⋈_{ricoveri.Reparto=medici.Reparto} medici

Le tuple coinvolte concettualmente sono

 $10^5 \cdot 10^2 = 10^7$ (dieci milioni)

per produrre quante tuple?

Valutiamo la cardinalità del join

Non esiste nessun vincolo e non ci sono chiavi coinvolte, quindi dobbiamo stimare la cardinalità:

```
|r1 \bowtie_{ricoveri.Reparto=medici.Reparto} medici| = min{1/VAL(Reparto, r1), 1/VAL(Reparto, medici)} \cdot CARD(r1) \cdot CARD(medici)
= min{1/10, 1/10} \cdot 10^5 \cdot 10^2
= 1/10 \cdot 10^5 \cdot 10^2 = 10^6
```

A questo punto abbiamo la selezione $\sigma_{p1 \wedge p2 \wedge p3}$ che elabora le 10⁶ tuple del risultato precedente (r2) e produce:

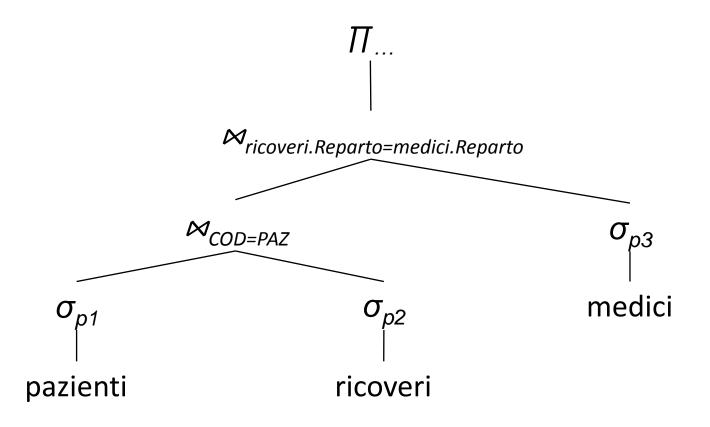
$$|\sigma_{p1 \wedge p2 \wedge p3}| =$$
 $f_{p1} \cdot f_{p2} \cdot f_{p3} \cdot CARD(r2) = 1/100 \cdot 1/10 \cdot 1/100 \cdot 10^{6}$
 $= 10$

Qual è la massa di tuple coinvolte dall'interrogazione?

Bisogna sommare le tuple coinvolte dal primo join + tuple coinvolte dal secondo join + tuple coinvolte dalla selezione: $10^{10} + 10^7 + 10^6$

E' sufficiente considerare l'ordine di grandezza, ovvero: 10^{10}

Consideriamo ora il risultato dell'ottimizzazione logica



Quante sono le tuple coinvolte dalla selezione σ_{p1} ?

Sono esattamente le tuple della relazione *pazienti*, ovvero 10⁵

Quante tuple produce?

$$|\sigma_{p1}| = f_{p1} \cdot CARD(pazienti) = 1/100 \cdot 10^5 = 10^3$$

Quante sono le tuple coinvolte dalla selezione σ_{p2} ?

Sono esattamente le tuple della relazione *ricoveri*, ovvero 10⁵

Quante tuple produce?

$$|\sigma_{p2}| = f_{p2} \cdot CARD(ricoveri) = 1/10 \cdot 10^5 = 10^4$$

Quante sono le tuple coinvolte dal join $\sigma_{p1}(pazienti) \bowtie_{COD=PAZ} \sigma_{p2}(ricoveri)?$

Questa volta il join lavora su $10^3 \cdot 10^4 = 10^7$ tuple

Quante tuple produce?

Quante tuple produce

$$\sigma_{p1}(pazienti) \bowtie_{COD=PAZ} \sigma_{p2}(ricoveri)$$
?

Stavolta non si può più sfruttare il vincolo di integrità referenziale, in quanto non è più detto che le tuple in *ricoveri* trovino delle tuple corrispondenti in *pazienti*

La selezione ha alterato il vincolo!

Devo quindi stimare l'equi-join

```
|\sigma_{p1}(pazienti)| \approx_{COD=PAZ} \sigma_{p2}(ricoveri)| = min{1/VAL(COD, <math>\sigma_{p1}(pazienti)), 1/VAL(PAZ, \sigma_{p2}(ricoveri))}. 
 CARD(\sigma_{p1}(pazienti)) \cdot CARD(\sigma_{p2}(ricoveri))
```

Non ho però $VAL(COD, \sigma_{p1}(pazienti))$

La selezione σ_{p1} non riguarda COD, ma il DBMS conosce questi dati:

- VAL(COD, pazienti) = 10⁵
- $CARD(\sigma_{p1}(pazienti)) = f_{p1} \cdot CARD(pazienti) = 1/100 \cdot 10^5 = 10^3$

Euristica del DBMS per la stima

L'euristica che il DBMS assume nello stimare il numero di valori distinti di codice che proviene dalla selezione con predicato *p1* sulla tavola pazienti è di prendere il

$$min\{10^5, 10^3\}$$

Infatti non possono esserci più di 10³ valori distinti

La stima si effettua cioè con la seguente formula:

```
VAL(COD, \sigma_{p1}(pazienti)) = min\{VAL(COD, pazienti), CARD(\sigma_{p1}(pazienti))\}
```

Euristica del DBMS per la stima

Formula generale per la stima di

$$|\sigma_{p1}(r(A)) \bowtie_{A_i = B_j} \sigma_{p2}(s(B))| =$$

$$min\{1/VAL(A_i, \sigma_{p1}(r)), 1/VAL(B_i, \sigma_{p2}(s))\}$$

$$\cdot CARD(\sigma_{p1}(r)) \cdot CARD(\sigma_{p2}(s))$$

con

- $VAL(A_i, \sigma_{p1}(r)) = min\{ VAL(A_i, r), CARD(\sigma_{p1}(r)) \}$
- $VAL(B_{j}, \sigma_{p2}(s)) = min\{ VAL(B_{j}, r), CARD(\sigma_{p2}(s)) \}$

quando A_i e B_j non sono coinvolti nei predicati di selezione

Non ho neanche il $VAL(PAZ, \sigma_{p2}(ricoveri))$

Il DBMS conosce questi dati:

- *VAL(PAZ,ricoveri) = 10*⁵
- $CARD(\sigma_{p2}(ricoveri)) = f_{p2} \cdot CARD(ricoveri) = 1/10 \cdot 10^5 = 10^4$

Di conseguenza

```
VAL(PAZ, \sigma_{p2}(ricoveri)) = min\{VAL(PAZ, ricoveri), CARD(\sigma_{p2}(ricoveri))\} = min\{10^5, 10^4\} = 10^4
```

```
Quante tuple produce
                       \sigma_{p1}(pazienti) \bowtie_{COD=PAZ} \sigma_{p2}(ricoveri)?
                       |\sigma_{p1}(pazienti)| \approx_{COD=PAZ} \sigma_{p2}(ricoveri)|
     min\{1/VAL(COD, \sigma_{p1}(pazienti)), 1/VAL(PAZ, \sigma_{p2}(ricoveri))\}
                  CARD(\sigma_{p1}(pazienti)) \cdot CARD(\sigma_{p2}(ricoveri))
          min\{1/10^3, 1/10^4\} \cdot 10^3 \cdot 10^4 = 1/10^4 \cdot 10^3 \cdot 10^4 = 10^3
```

Quante sono le tuple coinvolte dalla selezione σ_{p3} ?

Sono esattamente le tuple della relazione *medici*, ovvero 10²

Quante tuple produce?

$$|\sigma_{p3}| = 1$$

(è una selezione su MATR che è chiave, quindi produce una sola tupla)

Quante sono le tuple coinvolte dal join del risultato del join precedente (r1) con *medici*?

 $r1 \bowtie_{ricoveri.Reparto=medici.Reparto} \sigma_{p3}(medici)$

Questa volta il join lavora su $10^3 \cdot 1 = 10^3$ tuple

Quante tuple produce?

Non è interessante (esercizio)

Qual è la massa di tuple coinvolte dall'interrogazione?

Bisogna sommare le tuple coinvolte dalle tre selezioni + tuple coinvolte dal primo join + tuple coinvolte dal secondo join: $10^5 + 10^5 + 10^7 + 10^2 + 10^3$

E' sufficiente considerare il valore dominante, ovvero:

10⁷

Che è **mille volte meno** della massa di tuple coinvolte senza ottimizzazione logica!

4. Ricondurre ad un'unica selezione le selezioni multiple

$$- \qquad \sigma_{p1}(\sigma_{p2}(r)) \rightarrow \sigma_{p1 \wedge p2}(r)$$

- 5. Riconoscere le sequenze di join
 - $\sigma_{\theta}(r \times s) \rightarrow r \bowtie_{\theta} s$
- 6. Ricondurre ad un'unica proiezione le proiezioni multiple
 - $\prod_{X} \prod_{X,Y} (r) \rightarrow \prod_{X} (r)$
- 7. Esame delle varianti dell'albero di parsificazione dovute alle proprietà associative (scegliere la variante di costo minimo)

Esame delle varianti dell'albero di parsificazione dovute alle proprietà associative (scegliere la variante di costo minimo)

- L'ottimizzatore cerca una configurazione dell'albero di parsificazione che riduca ulteriormente la massa di tuple concettualmente elaborate
- Principalmente questo passo consiste nella ricerca di parentesizzazioni alternative, e meno costose, di join multipli

Questo passo ha delle difficoltà computazionali non indifferenti Consideriamo una sequenza di join:

$$r_1 \bowtie r_2 \bowtie ... \bowtie r_n$$

- Le configurazioni possibili dovute alle proprietà associative crescono esponenzialmente con n
 - n=3, 2 configurazioni
 - n=4, 5 configurazioni
 - n=5, 14 configurazioni
 - n=10, 4862 configurazioni

$$configurazioni = \frac{1}{n} \binom{2(n-1)}{n-1}$$

Esempio con 4 relazioni

$$((r_1 \bowtie r_2) \bowtie r_3) \bowtie r_4$$

$$(r_1 \bowtie (r_2 \bowtie r_3)) \bowtie r_4$$

$$r_1 \bowtie ((r_2 \bowtie r_3) \bowtie r_4)$$

$$r_1 \bowtie (r_2 \bowtie (r_3 \bowtie r_4))$$

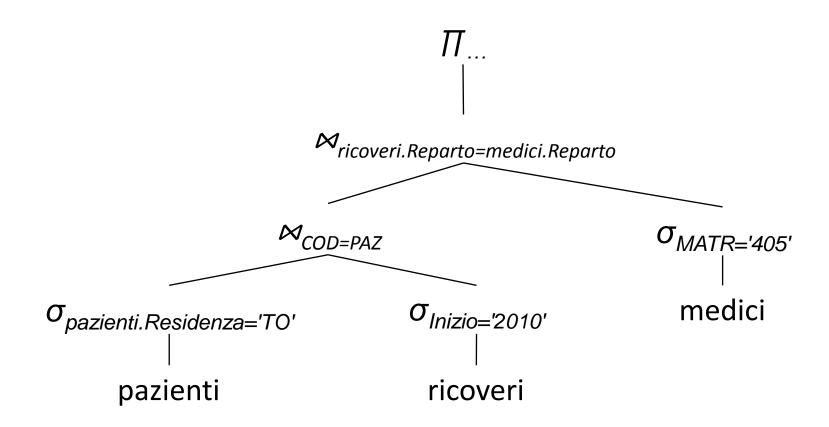
$$(r_1 \bowtie r_2) \bowtie (r_3 \bowtie r_4)$$

 Gli ottimizzatori non esplorano tutte le possibili configurazioni ma cercano una configurazione subottimale

 La scelta dell'ottimizzatore è quella di anticipare il prima possibile i join tra relazioni con cardinalità bassa

 Si cerca il join a cardinalità minima dei sottoalberi e si esegue per primo e così via

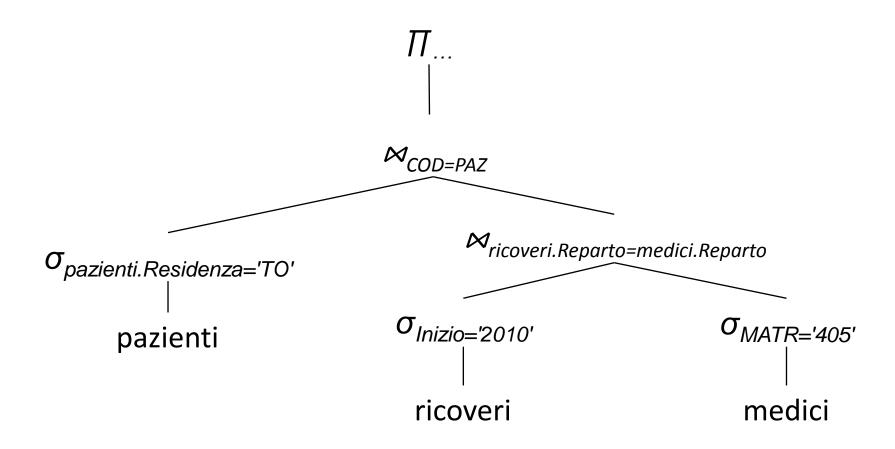
E' vero che il join può lavorare su una massa di tuple enorme, ma solitamente, in uscita, produce un numero di tuple limitato (dovuto alla selettività del suo predicato theta)



La cardinalità di $\sigma_{p3}(medici)$ è 1, quindi l'ottimizzatore cercherà di eseguire prima un join che coinvolge $\sigma_{p3}(medici)$

Tra gli altri due sottoalberi, quello a cardinalità minima (10^3) è $\sigma_{\rm p1}$ (pazienti)

Ma medici non può fare join con pazienti, quindi l'ottimizzatore è costretto a scegliere σ_{p2} (ricoveri)



Analisi quantitativa

I dati delle tre selezioni sono identici

- σ_{p1} elabora 10⁵ tuple e $|\sigma_{p1}| = 10^3$
- σ_{p2} elabora 10⁵ tuple $|\sigma_{p2}| = 10^4$
- σ_{p3} elabora 10² tuple $|\sigma_{p3}| = 1$

```
Il join \sigma_{p2} \bowtie_{ricoveri.Reparto=medici.Reparto} \sigma_{p3} dovrà elaborare 10^4 \cdot 1 = 10^4 tuple e produrrà  min\{1/VAL(Reparto, \sigma_{p3} (medici)), 1/VAL(Reparto, \sigma_{p2} (ricoveri))\} \cdot \\  CARD(\sigma_{p3} (medici)) \cdot CARD(\sigma_{p2} (ricoveri)) = \\  min\{1/1, 1/10\} \cdot 1 \cdot 10^4 = \\  1/10 \cdot 10^4 = 10^3
```

Analisi quantitativa

Per l'ultimo join tra $\sigma_{p1}(pazienti)$ e il risultato del join precedente $10^3 \cdot 10^3 = 10^6$ tuple elaborate

Qual è la massa di tuple coinvolte dall'interrogazione?

Bisogna sommare le tuple coinvolte dalle tre selezioni + tuple coinvolte dal primo join + tuple coinvolte dal secondo join: $10^2 + 10^5 + 10^5 + 10^6$

E' sufficiente considerare il valore dominante, ovvero:

In seguito...

 Quando l'ottimizzatore logico finisce il suo lavoro e invia l'albero di parsificazione all'ottimizzatore fisico, quest'ultimo mette, al posto dei nodi, dei veri e propri blocchi di codice (ad esempio: il codice per la selezione, il codice per il join...)

 L'ottimizzatore fisico sceglie, all'interno delle sue librerie, il codice che corrisponde all'algoritmo che muove meno pagine